

Historias de IA Explicable
Proyecto del Máster en Inteligencia Artificial

Facultad de Informática, UCM

Curso 2025/26

Profesora: Belén Díaz Agudo

El objetivo de este proyecto es aplicar, analizar o proponer técnicas de Inteligencia Artificial Explicable (XAI) a un problema real, y documentar el trabajo en forma de **capítulo de un libro colaborativo** que será publicado online siguiendo el espíritu del proyecto [XAI Stories](#) de Przemysław Biecek.

Cada equipo (o estudiante individual) desarrollará un caso de estudio completo y lo presentará como un capítulo autocontenido que combine código reproducible con narrativa clara.

En el campus se ha habilitado **una entrega opcional** para subir la **propuesta de tema** y recibir feedback antes de comenzar el trabajo.

Esta propuesta debe incluir los nombres de los integrantes del equipo, Título provisional del proyecto y un párrafo de resumen indicando:

- El dataset elegido (o el tema teórico).
- El enfoque propuesto (qué técnicas XAI se van a usar o estudiar).
- Por qué os parece interesante o relevante, si partís de algo ya hecho.

¿Qué hay que entregar al final?#

1. Notebook ejecutable (.ipynb)

- Código completo y reproducible (Python).
- Celdas de texto en Markdown que formen la narrativa del capítulo.
- Gráficos y visualizaciones integrados.
- Instrucciones claras para reproducir el entorno (archivo requirements.txt).

2. Texto del capítulo

Os recomiendo el formato Quarto Markdown (.qmd) para el texto narrativo del capítulo, estructurado con las siguientes secciones mínimas:

Título del capítulo

Autores

Resumen

Párrafo breve describiendo el problema, el enfoque y las conclusiones principales.

Introducción

Contexto del problema, motivación y relevancia.

Datos

Descripción del dataset: origen, variables, preprocesamiento.

Modelo(s)

Descripción y justificación de los modelos utilizados. Métricas de rendimiento.

Explicaciones

Técnicas XAI aplicadas, resultados e interpretación.

Conclusiones

Hallazgos principales, limitaciones y posibles extensiones.

Referencias

Nota: Si el notebook ya contiene toda la narrativa bien estructurada con estas secciones, puede servir como ambos entregables. No es necesario duplicar el texto.

Tipos de proyecto

Como hemos comentado en clase el tema y el dataset son de **libre elección**.

Podéis elegir distintos tipos de proyecto

A) Proyecto aplicado: Explicar un modelo sobre un dataset

Elegir un problema y un dataset, entrenar uno o varios modelos, y aplicar técnicas XAI vistas en clase para extraer conclusiones.

Fuentes de datasets: Kaggle, UCI Machine Learning Repository, OpenML, datos.gob.es, data.europa.eu, Hugging Face Datasets, o cualquier fuente pública.

También es válido usar un dataset relacionado con vuestro TFM, con trabajos anteriores (como TFGs), prácticas en empresa o intereses personales. Siempre documentando correctamente el punto de partida del trabajo y teniendo en cuenta los derechos de los datos (porque se van a publicar con el libro).

B) Proyecto teórico/survey: Estudio en profundidad de un tema XAI

Revisión crítica y análisis de un tema teórico, acompañado de ejemplos o experimentos ilustrativos. Os sugiero algunos temas:

- ¿Se puede explicar la IA generativa? Intentos y limitaciones (explicabilidad de LLMs, diffusion models...).
- Limitaciones conocidas de LIME/SHAP: adversarial attacks contra explicadores con ejemplos. Evaluación teórico-práctica de cómo modelos manipulados pueden producir explicaciones engañosas en LIME y SHAP. Diseño de ataques adversarios que mantengan la precisión del modelo pero alteren las explicaciones generadas por LIME y SHAP. Análisis

experimental de escenarios en los que LIME y SHAP generan explicaciones inconsistentes o manipulables.

- Fairness y explicabilidad: cómo detectar y mitigar sesgos usando técnicas XAI y herramientas como FairLearn o AEQUITAS.
- Evaluación y métricas de calidad de las explicaciones: fidelidad, estabilidad, comprensibilidad ¿cómo sabemos si una explicación es suficiente?

C) Proponer algo nuevo, extensión o nuevo enfoque

Por ejemplo podéis:

- Diseñar un nuevo método de generación de instancias sintéticas para explicadores locales basados en instancias o proponer nuevas definiciones de vecindario para LIME mejorando las propuestas en la sesión 3 aplicada a algún ejemplo (¿vecindarios basados en conocimiento, con ontologías o grafos?).
- Proponer algún explicador nuevo.
- Combinar técnicas XAI con visualización interactiva (dashboards explicativos) o personalizar la interfaz de explicación. Explicar en lenguaje natural los resultados de los gráficos de explicación vistos en clase para usuarios no expertos. ...

Criterios de evaluación

La evaluación del trabajo se basará en la calidad técnica y narrativa del documento, en la **originalidad** del trabajo y la **dificultad y ambición** del proyecto. El código proporcionado tiene que estar adecuadamente documentado para permitir la replicación de los resultados. Se valorará ir más allá de aplicar una librería sin más: **interpretar, comparar y extraer conclusiones** a partir de las explicaciones aportar una perspectiva de negocio, ética o dominio sobre las explicaciones obtenidas (según intereses)

Entrega final del proyecto 25 de mayo de 2025

Subir al campus un archivo **.zip** que contenga los siguientes elementos:

- **equipo_nombre/** (carpeta principal del proyecto)
- **capitulo.ipynb**: notebook con el código reproducible o **capitulo.qmd**: texto del capítulo (o solo. ipynb si la narrativa está integrada en el notebook)
- **requirements.txt**: dependencias de Python (o **environment.yml** si se usa conda)

- **datos/**: datos utilizados en el proyecto o un script para descargarlos (si los datos no son demasiado pesados)
- **figuras/**: imágenes generadas (si no se generan directamente en el notebook)
- **README.md**: instrucciones breves para reproducir el proyecto
- **Vídeo (opcional, recomendado)**: breve explicación del proyecto y de los principales resultados. No habrá defensa oral, pero se valorará acompañar la entrega con un vídeo de 3-5 minutos explicando el proyecto. Los vídeos NO se publicarán en el libro.

Los capítulos (no los vídeos) serán compilados y publicados como un libro online de acceso abierto, al estilo de [XAI Stories](#). Vuestro trabajo será visible públicamente y podrá servir como referencia para futuros estudiantes y profesionales.